

Wearable Health Data & Interpretable Machine Learning

Topic 2 — PhysioNet: Wearable Device Dataset (Hongn et al., 2025)

Endpräsentation · Juli 2026

Einleitung

FORSCHUNGSFRAGE

Welche aus Wearable-Signalen abgeleiteten Merkmale sind für die Unterscheidung von Ruhe, psychischem Stress, aerober und anaerober Belastung besonders relevant, wie lassen sich ihre Einflüsse nachvollziehen und welche Einschränkungen ergeben sich bei ihrer Nutzung mit typischen Consumer-Wearables?

Agenda

01 Klassen

02 Vorverarbeitung

03 Modelle & Evaluationsstrategie

04 Ergebnisse & Erklärbarkeit

05 Fazit & Ausblick

Klassen

Ruhe

Entspannter Grundzustand, niedrige Herzfrequenz, Keine Bewegung

Psychischer Stress

Aktivierung aus dem Kopf, Herzfrequenz und Schwitzen steigen, allerdings keine Bewegung

Anaerobe Belastung (Sport)

Gleichmäßige, ausdauernde Anstrengung, Herzfrequenz steigt gleichmäßig und bleibt erhöht

Aerobe Belastung (Sport)

Kurze, Maximale Kraftstöße, erzeugt typisches Sägezahn Muster in Herzfrequenz

Daten & Ausgangslage

36

Probanden

3

Protokolle (Stress,
Aerobic, Anaerobic)

5

Physiologische
Signale

Gerät:

- Empatica E4 wearable – ein medizinisches Wearable

Signale

Das Empatica E4 Wearable liefert fünf physiologische Signale



EDA

4 Hz

Elektrische
Hautleitfähigkeit



BVP

64 Hz

Pulswelle →
Herzrate, HRV



HR

1 Hz

Herzrate



ACC

32 Hz

3-Achsen
Beschleunigung



TEMP

4 Hz

Hauttemperatur


Vorverarbeitungsschritte



Finaler Datensatz: 593 Blöcke von 31 Personen

Klassenungleichgewicht

Der bereinigte Datensatz ist nicht vollständig ausgeglichen



Modellabhängiges Klassenbalancing gewichtet Fehler bei kleineren Klassen stärker

Trainierte Modelle

Logistische Regression

Linear Classifier

Lineares Modell als interpretierbare Baseline

EBM

Explainable Boosting Machine

vollständig interpretierbares Non-Linear-Modell

XGBoost

Gradient Boosting Decision Trees

Leistungsstarkes Baumensemble, als Black-Box-Modell ohne direkte Interpretierbarkeit

TabPFN


Vortrainierter Transformer für Tabellendaten

Prior-fitted Netzwerk, sagt ohne klassisches Training direkt vorher

Evaluationsstrategie & Metriken

LEAVE-ONE-SUBJECT-OUT CROSS-VALIDATION

Das Modell wird jeweils auf 30 Personen trainiert und an der verbleibenden Person getestet → das reihum, sodass jede Person genau einmal Testperson ist.



METRIKEN

Accuracy

Precision Macro


Recall Macro

F1 Macro

ROC-AUC


Hauptmetrik: F1 Macro – pro Klasse einzeln berechnet und gleichgewichtet gemittelt, da die vier Klassen unterschiedlich groß sind und keine davon weniger zählen soll. F1 verbindet außerdem Recall und Precision.

Finale Modellleistung (F1-macro)




EBM – Erklärbarkeit

EBM 4-Klassen - Shape Functions Top-6 Features (mit ACC)
y-Achse = additiver Beitrag zur Klassen-Log-Odds (Feature standardisiert); je eine Linie pro Klasse




Klarste Fälle je Klasse SHAP-Beiträge (mit ACC)


Klarster Fall 'rest' P(rest) = 1.00




Klarster Fall 'stress' — P(stress) = 1.00




Klarster Fall 'aerobic' P(aerobic) = 1.00




Klarster Fall 'sprint' P(sprint) = 1.00



Performance mit ACC und Ohne



Merkmaleinflüsse auf die Modelle



Grenzen der Erklärbarkeit

Zwei zentrale Einschränkungen unserer Erklärbarkeits-Analyse

1

ACC-Konfundierung

Bewegung ist im Studiendesign fast deckungsgleich mit der Sportklasse – Beschleunigungsmerkmale könnten eher das Design als echte physiologische Unterschiede abbilden.

2

Wichtigkeit $\neq$ Kausalität

SHAP- und EBM-Werte zeigen, welche Merkmale das Modell nutzt – nicht, was die Zustände tatsächlich verursacht.

Fazit

ANTWORT AUF DIE FORSCHUNGSFRAGE

1

Unterscheidung grundsätzlich möglich

Ruhe, psychischer Stress, aerobe und anaerobe Belastung lassen sich auch bei unbekannten Personen unterscheiden. TabPFN erzielt die höchste Leistung, die EBM bleibt dabei nachvollziehbar.

2

Bewegung & Herzaktivität entscheidend

Beschleunigungsmerkmale liefern den größten Leistungsbeitrag. Fehlen sie, übernehmen IBI-Mittelwert, Temperatur- und Herzfrequenz-Streuung sowie EDA-Merkmale die Trennung.

3

Praktische Übertragbarkeit auf Consumer-Wearables bleibt offen

Ein Set aus HR, HRV und Beschleunigung erhält einen Großteil der Leistung → fällt zusätzlich die Beschleunigung weg, sinkt die Leistung deutlich.

Grenzen



Laborbedingungen

Zustände wurden unter kontrollierten Bedingungen erzeugt → im Alltag meist weniger klar



Kleine, homogene Stichprobe

Nur 31 überwiegend junge, gesunde Personen → Übertragbarkeit auf Ältere oder Kranke ungeprüft



Fehlende Alltagsbedingungen


Wechselnde Temperatur, Wetter, Tageszeit und Tragesitz beeinflussen v. a. EDA und Hauttemperatur



Einzelklassen-Annahme

Reale Zustände treten oft gleichzeitig auf (z. B. Stress + Bewegung) → unser Modell ordnet allerdings immer genau eine Klasse zu

Ausblick



Der nächste Schritt ist kein komplexeres Modell, sondern eine realistischere Datengrundlage

Vielen Dank für Ihre Aufmerksamkeit!

Fragen & Diskussion

Validierungsmethodiken

Probandenweiser Split (LOSOCV – Leave One Subject Out)

- Modell auf 30 Personen trainiert und auf übrigen getestet und das reihum → jeder genau einmal Testperson
- Am Ende: Array mit 445 Vorhersagen, dann werden die verschiedenen Metriken auf diesem Array berechnet

Metriken

Accuracy

Anteil aller Blöcke die richtig klassifiziert wurde

Precision

Wie präzise sind meine Treffer?

Recall

Wie viele hab ich gefunden?

F1 Macro

F1 Score für jede Klasse einzeln und daraus der Durchschnitt

ROC-AUC

Wie gut trennt das Modell insgesamt Positiv und Negativ?