

Wearable Health Data & Interpretable Machine Learning

Topic 2 — PhysioNet: Wearable Device Dataset (Hongn et al., 2025)

2. Zwischenpräsentation · Juni 2026

Prediction Target

Ruhe

Entspannter Grundzustand, niedrige Herzfrequenz, Keine Bewegung

Psychischer Stress

Aktivierung aus dem Kopf, Herzfrequenz und Schwitzen steigen, allerdings keine Bewegung

Anaerobe Belastung (Sport)

Gleichmäßige, ausdauernde Anstrengung, Herzfrequenz steigt gleichmäßig und bleibt erhöht

Aerobe Belastung (Sport)

Kurze, Maximale Kraftstöße, erzeugt typisches Sägezahn Muster in Herzfrequenz

Binäre Klassifikation

Sport (Aerobe + Anaerobe Belastung)

Aktivierung aus dem Körper, Aerobe und Anaerobe Belastung zusammengefasst

Psychischer Stress

Aktivierung aus dem Kopf, Herzfrequenz und Schwitzen steigen, allerdings keine Bewegung

Agenda

01

Aktueller Stand

02

Trainierte Modelle

03

Ausblick

1.1 PhysioNet Datensatz — Überblick

36

Probanden
(S01–S18, f01–f13)

3

Session-
Kategorien

5

Physiolog.
Signale

Gerät:

- Empatica E4 wearable


Protokollversionen:

- v1 (S01–S18): STRESS + AEROBIC + ANAEROBIC, getrennte Tage
- v2 (f01–f13): neue Version, mehr Pausen

1.2 Empatica E4 — Signale & Sampling Rates

EDA 4 Hz	BVP 64 Hz	HR 1 Hz	ACC 32 Hz	TEMP 4 Hz
Elektrische Hautleitfähigkeit	Blutvolumenpuls → Herzrate, HRV	Herzrate	3-Achsen Beschleunigung	Hauttemperatur

1.3 Vorverarbeitungs-Pipeline




22 Features aus 5 Signal-Modalitäten

HR (2)	EDA (6)	HRV (6)	ACC (5)	TEMP (3)
hr_mean	mean_tonic_eda	max_ibi	x_std	temp_mean
hr_std	std_tonic_eda	min_ibi	y_std	temp_std
	std_phasic_eda	ibi_mean	z_std	temp_slope
	tonic_ratio_down	rmssd	acc_mean	
	peaks_density	LF_peak	acc_ratio_down	
	mean_recoverytime	LF_n		

Alle Features: statistisch (mean, std, ratio), NeuroKit2 (SCR-Peaks, PPG→IBI, HRV)

1.3 Vorverarbeitungs-Pipeline



2. Trainierte ML - Modelle

Logistische Regression

Linear Classifier

Lineares Modell als interpretable Baseline → schnell trainierbar, direkt erklärbar durch Koeffizienten

EBM

Explainable Boosting Machine
(InterpretML)

Generalized Additive Model mit Interaktionstermen → vollständig interpretierbares Non-Linear-Modell

XGBoost

Gradient Boosting Decision Trees

Ensemble Methode auf Entscheidungsbäumen → Black Box Modell

Random Forest

Ensemble aus Entscheidungsbäumen

Robuste Vergleichsmethode → zeigt ob XGBoost durch Boosting besser ist

2.1 Problem: Klassen Ungleichgewicht

Sport Klasse

303 Blöcke

Stress Klasse

142 Blöcke

→ Klassenbalancing: Stress Klasse beim Training höheres Gewicht zuweisen → Fehler wird 2,13 mal so schwer gewichtet

→ Alternative: SMOTE

2.2 Validierungsmethodiken

Probandenweiser Split (LOSOCV – Leave One Subject Out)

- Modell auf 30 Personen trainiert und auf übrigen getestet und das reihum → jeder genau einmal Testperson
- Am Ende: Array mit 445 Vorhersagen, dann werden die verschiedenen Metriken auf diesem Array berechnet

Metriken

Accuracy

Anteil aller Blöcke die richtig klassifiziert wurde

Precision

Wie präzise sind meine Treffer?

Recall

Wie viele hab ich gefunden?

F1 Macro







F1 Score für jede Klasse einzeln und daraus der Durchschnitt

ROC-AUC

Wie gut trennt das Modell insgesamt Positiv und Negativ?


2.3 Ergebnisse - Datenabgleich Modelle

4-Modell-Vergleich — LOSO-CV (mit Accelerometer) LogReg · Random Forest · EBM · XGBoost




2.3 Ergebnisse - Datenabgleich Modelle

Top-Features MIT ACC
rot = Stress ↑, blau = Stress ↓









Top-Features MIT ACC
XGBoost Gain-Importance



2.3 Ergebnisse - Datenabgleich Modelle


4-Modell-Vergleich — LOSO-CV (ohne Accelerometer) LogReg · Random Forest · EBM · XGBoost

LOSO-Metriken (gepoolt) — ohne Accelerometer



2.4 Feature Relevanz

EBM - Shape Functions der Top-6 Features
(y-Achse = Beitrag zur Log-Odds, positiv = Stress ↑)



2.5 SMOTE (ohne ACC)

Metrik	LR Baseline	LR SMOTE	XGB Baseline	XGB SMOTE
Accuracy	0,807	0,804	0,843	0,827
ROC-AUC	0,891	0,889	0,909	0,910
F1-Macro	0,787	0,782	0,822	0,805
Precision	0,821	0,826	0,762	0,739
Recall	0,746	0,773	0,789	0,768

→ SMOTE ist insgesamt minimal schlechter

Ausblick

1

Dashboard

2

Garmin / Apple Watch Daten

3

4 Klassen

4

Vergleich der Modelle Erklärbarkeit

Today · Monday, 23 June


Physiological state overview · Gera

P

DAY TIMELINE



BALANCE



ACTIVITY SPLIT



● Stress	2.8 h
● Aerobic	37 min
● Sprint	10 min
● Rest	~11 h



Stress detected · 10:00–11:15 and 12:00–14:00

Elevated EDA + HR across two blocks — 2.8 h total stress classified today.



Exercise goal reached · 47 min

Aerobic + sprint sessions detected. Movement target achieved.



Stress-to-sport ratio looks off

2.8 h stress vs. 47 min exercise — a short walk would help recovery.





Time for a walk?

High stress today. 15 min low-intensity movement supports recovery.

Start

Apple Watch × GADA Stress Model — Persönliches 30-Tage Dashboard



Feature-Abdeckung

✓ Direkt (Apple Watch): 2



— Abgeleitet: 2

✗ Imputed (EDA): 6

✗ Imputed (Temp.): 3

✗ Imputed (IBI): 3

4/16 Features real
12/16 Imputiert



△ 12 von 16 Features mit Trainings-Median imputiert (EDA vollständig, Temperatur vollständig, IBI teilweise). Predictions sollten als explorativ und nicht als klinisch valide betrachtet werden.

Vielen Dank für Ihre Aufmerksamkeit!

Fragen & Diskussion